

Demonstrații Cursuri

Metode Numerice pentru Sisteme Neliniare și Optimizare

Prof. dr. Liviu Marin

Ianuarie 2026

Cursul I

Teorema 3.

Dacă metoda **Jacobi** converge și $0 < \omega \leq 1$, atunci **metoda JOR converge**.

Dem.

$$M_J = I_n - D^{-1}A.$$

$$\begin{aligned} M_{JOR} &= I_n - \omega D^{-1}A \\ &= I_n - \omega D^{-1}A - \omega I_n + \omega I_n \\ &= I_n - \omega I_n + \omega I_n - \omega D^{-1}A \\ &= (1 - \omega)I_n + \omega(I_n - D^{-1}A) \\ &= (1 - \omega)I_n + \omega M_J. \end{aligned}$$

Fie $\lambda \in \sigma(M_J)$. Atunci:

$$\begin{aligned} M_{JOR}v &= [(1 - \omega)I_n + \omega M_J]v \\ &= (1 - \omega)I_nv + \omega M_Jv \\ &= (1 - \omega)v + \omega \lambda v \\ &= (1 - \omega + \omega \lambda)v. \end{aligned}$$

Rezultă:

$$(1 - \omega + \omega \lambda) \in \sigma(M_{JOR}) \quad \Rightarrow \quad \rho(M_{JOR}) = \max |1 - \omega + \omega \lambda|.$$

Cum:

$$|1 - \omega + \omega \lambda| \leq (1 - \omega) + \omega |\lambda| \leq (1 - \omega) + \omega \rho(M_J) \leq (1 - \omega) + \omega \cdot 1 = 1 - \omega + \omega = 1,$$

rezultă că:

Metoda JOR converge.

□

Teorema 4.

Fie $A \in \mathcal{M}_n(\mathbb{R})$ o matrice **simetrică pozitiv definită (SPD)**. Dacă $0 < \omega < \frac{2}{\rho(D^{-1}A)}$, atunci **metoda JOR converge**.

Dem.

$$M_{JOR} = I_n - \omega D^{-1}A.$$

Deoarece A este SPD $\Rightarrow D^{-1}A$ este PD.

Fie $\lambda \in \sigma(D^{-1}A)$. Atunci:

$$\begin{aligned} M_{JOR}v &= (I_n - \omega D^{-1}A)v \\ &= I_nv - \omega D^{-1}Av \\ &= v - \omega \lambda v \\ &= (1 - \omega \lambda)v. \end{aligned}$$

Rezultă:

$$(1 - \omega \lambda) \in \sigma(M_{JOR}) \quad \Rightarrow \quad \rho(M_{JOR}) = \max |1 - \omega \lambda|.$$

Notăm cu $\lambda_{\max} = \rho(D^{-1}A)$.

Conform cerinței:

$$0 < \omega < \frac{2}{\lambda_{\max}}$$

$$\Rightarrow 0 < \omega \lambda_{\max} < 2$$

$$\Rightarrow -1 < \omega \lambda_{\max} - 1 < 1$$

$$\Rightarrow -1 < 1 - \omega \lambda_{\max} < 1$$

$$\Rightarrow |1 - \omega \lambda_{\max}| < 1$$

$$\Rightarrow \rho(M_{JOR}) < 1$$

rezultă că:

Metoda JOR converge.

□

Cursul II

Exercițiul 1 Să se dezvolte algoritmul **GSb**.

Dem. Pentru metoda **GSb** avem:

$$P_{GSb} = D + U.$$

Această matrice este **inversabilă** dacă și numai dacă:

$$\det(D + U) \neq 0 \iff \prod_{i=1}^n a_{ii} \neq 0 \iff a_{ii} \neq 0, \forall i = 1, \dots, n.$$

Ecuția i pentru metoda **GSb** este:

$$a_{i1}x_1^{(k-1)} + a_{i2}x_2^{(k-1)} + \dots + a_{ii}x_i^{(k)} + \dots + a_{in}x_n^{(k)} = b_i.$$

De aici rezultă:

$$x_i^{(k)} = \frac{1}{a_{ii}} \left[b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k-1)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} \right]. \quad (1)$$

Ca algoritm, se parcurge sistemul de la **ultima** ecuație ($i = n$) până la **prima** ($i = 1$) și se calculează fiecare x_i cu formula (1). $\square$

Teorema 1.

Dacă $A \in \mathcal{M}_n(\mathbb{R})$ este **strict diagonal dominantă**, atunci metoda **GSb** converge.

Dem.

Obs. Deoarece $M_{GSb}(A) = M_{GS}(A^T)$, rezultă că metoda **Gauss-Seidel descendentă** aplicată lui A este echivalentă cu metoda **Gauss-Seidel ascendentă** aplicată lui A^T .

$\Rightarrow$ Se poate folosi demonstrația din curs pentru metoda GSa aplicată lui A^T .

$\square$

Teorema 2.

Dacă $A \in \mathcal{M}_n(\mathbb{R})$ este **SPD**, atunci metoda **GSb** converge.

Dem.

Obs. În mod similar cu exercițiul anterior, $M_{GSb}(A) = M_{GS}(A^T)$, rezultă că metoda **Gauss-Seidel descendentă** aplicată lui A este echivalentă cu metoda **Gauss-Seidel ascendentă** aplicată lui A^T .

$\Rightarrow$ Se poate folosi demonstrația din curs pentru metoda GSa aplicată lui A^T .

□

Teorema 1 Kahan.

Pentru orice $\omega \in \mathbb{R}$, se are $\rho(M_{SORb}(\omega)) \geq |\omega - 1|$.

Dem. Observăm că $M_{SORb}(A, \omega) = M_{SOR}(A^T, \omega)$ și $\rho(M) = \rho(M^T)$. Aplicând teorema lui Kahan pentru $M_{SOR}(A^T, \omega)$, obținem afirmația. □

Corolar M metoda **SORb** nu converge pentru $\omega \in \mathbb{R} \setminus (0, 2)$.

Dem. Din teoremă, $\rho(M_{SORb}) \geq |1 - \omega| \geq 1$ când $\omega \notin (0, 2)$. □

Teorema 2 Ostrowski-Reich.

Dacă $A \in \mathcal{M}_n(\mathbb{R})$ este **SPD**, atunci metoda **SORb** converge $\Leftrightarrow \omega \in (0, 2)$.

Dem.

Obs. Fiindcă $P_{SOR}(A^T, \omega) = P_{SORb}(A, \omega)$ și $N_{SOR}(A^T, \omega) = N_{SORb}(A, \omega)$, rezultă $M_{SOR}(A^T, \omega) = M_{SORb}(A, \omega)$.

Prin urmare, demonstrația din curs pentru **SOR** aplicată lui A^T e identică la **SORb** aplicată lui A . □

Teorema 1.

- (i) Dacă A este simetrică $\Rightarrow$ matricile $P_{SSOR}(\omega)$ și $N_{SSOR}(\omega)$ sunt simetrice.
- (ii) Dacă A este simetrică și D pozitiv definită $\Rightarrow M_{SSOR}(\omega)$ are valori proprii reale nenegative.
- (iii) Dacă A este simetrică și D pozitiv definită $\Rightarrow [P_{SSOR}(\omega) + P_{SSOR}(\omega)^T - A]$ este SPD $\Leftrightarrow \omega \in (0, 2)$.

Dem. $A = D + L + U$, $D^T = D$, $U = L^T$ (deoarece A este simetrică). Rezultă că:

$$P_{SSOR}(\omega) = \frac{1}{\omega(2-\omega)}(D + \omega L) D^{-1} (D + \omega L)^T, N_{SSOR}(\omega) = \frac{1}{\omega(2-\omega)}((1-\omega)D - \omega L) D^{-1} ((1-\omega)D - \omega U)$$

(i)

Fiecare matrice este de forma $X D^{-1} X^T \Rightarrow$ matricile $P_{SSOR}(\omega)$ și $N_{SSOR}(\omega)$ sunt simetrice.

(ii)

$$M_{SSOR}(\omega) = (D + \omega U)^{-1} D (D + \omega L)^{-1} [(1-\omega)D - \omega L] D^{-1} [(1-\omega)D - \omega U].$$

$A = D + L + U$ este simetrică $\Rightarrow U = L^T$ și $D = D^T$. Notăm:

$$X := (D + \omega L)^{-1} [(1-\omega)D - \omega L] D^{-1/2}.$$

Atunci:

$$M_{SSOR}(\omega) = D^{-1/2} X^T X D^{1/2}.$$

Matricea $X^T X$ este simetrică și semipozitiv definită, deci valorile proprii ale ei sunt reale și nenegative.

Deoarece M_{SSOR} este similară cu $X^T X$ (deoarece $D^{1/2}$ este inversabilă, iar $D^{1/2} M_{SSOR} D^{-1/2} = X^T X$) $\Rightarrow M_{SSOR}$ are aceleași valori proprii ca $X^T X$, deci reale și nenegative.

(iii)

$$\begin{aligned} P_{SSOR}(\omega) &= \frac{1}{\omega(2-\omega)} (D + \omega L) D^{-1} (D + \omega U), \\ P_{SSOR}(\omega)^T &= \frac{1}{\omega(2-\omega)} (D + \omega U) D^{-1} (D + \omega L), \\ P_{SSOR}(\omega) + P_{SSOR}(\omega)^T &= \frac{1}{\omega(2-\omega)} \left[(D + \omega L) D^{-1} (D + \omega U) + (D + \omega U) D^{-1} (D + \omega L) \right], \\ &= \frac{1}{\omega(2-\omega)} \left[(D + \omega L)(I + \omega D^{-1} U) + (D + \omega U)(I + \omega D^{-1} L) \right], \\ &= \frac{1}{\omega(2-\omega)} \left[2D + 2\omega(L + U) + \omega^2(LD^{-1}U + UD^{-1}L) \right]. \end{aligned}$$

$$\begin{aligned} P_{SSOR}(\omega) + P_{SSOR}(\omega)^T - A &= \frac{1}{\omega(2-\omega)} \left[2D + 2\omega(L + U) + \omega^2(LD^{-1}U + UD^{-1}L) \right. \\ &\quad \left. - \omega(2-\omega)D - \omega(2-\omega)(L + U) \right] \\ &= \frac{1}{\omega(2-\omega)} \left[(2 - \omega(2-\omega))D + (2\omega - \omega(2-\omega))(L + U) + \omega^2(LD^{-1}U + UD^{-1}L) \right]. \end{aligned}$$

Folosind $U = L^T$ și identitatea

$$LD^{-1}U + UD^{-1}L = (L + U) - D,$$

obținem:

$$\begin{aligned} P_{SSOR}(\omega) + P_{SSOR}(\omega)^T - A &= \frac{1}{\omega(2-\omega)} \left[(2 - 2\omega + \omega^2)D + \omega^2((L + U) - D) + \omega^2(L + U) \right] \\ &= \frac{1}{\omega(2-\omega)} \left[(2 - 2\omega)D \right] = \frac{2-\omega}{\omega} D. \end{aligned}$$

$$\boxed{P_{SSOR}(\omega) + P_{SSOR}(\omega)^T - A = \frac{2-\omega}{\omega} D.}$$

Cum D este PD, rezultă că termenul din stânga este SPD dacă $\frac{2-\omega}{\omega} > 0$, adică $\omega \in (0, 2)$. $\square$

Teorema 2 Ostrowski-Reich.

Dacă $A \in \mathcal{M}_n(\mathbb{R})$ este **SPD**, atunci metoda **SSOR** converge $\Leftrightarrow \omega \in (0, 2)$.

Dem. Dacă SSOR converge, atunci $\rho(M_{SSOR}) < 1$. Prin criteriul *Householder-John*:

$$P_{SSOR}(\omega) + P_{SSOR}(\omega)^T - A \text{ este SPD.}$$

Din demonstrația anterioară,

$$P_{SSOR} + P_{SSOR}^T - A = \frac{2 - \omega}{\omega} D,$$

iar D este PD (deoarece A este SPD). Așadar $(2 - \omega)/\omega > 0$, adică $\omega \in (0, 2)$.

Dacă $\omega \in (0, 2)$, atunci $\frac{2 - \omega}{\omega} D$ este SPD, deci $P_{SSOR} + P_{SSOR}^T - A$ este SPD. Aplicând criteriul *Householder-John* $\Rightarrow \rho(M_{SSOR}) < 1 \Rightarrow$ metoda SSOR converge.

□

Cursul III

Lema I

Fie $P \in \mathcal{M}_n(\mathbb{R})$ o matrice **SPD**. Atunci:

- (i) Dacă $A \in \mathcal{M}_n(\mathbb{R})$ este **simetrică**, atunci $P^{-1}A$ este simetrică în raport cu $(\cdot, \cdot)_P$.
- (ii) Dacă $A \in \mathcal{M}_n(\mathbb{R})$ este **PD**, atunci $P^{-1}A$ este PD în raport cu $(\cdot, \cdot)_P$.
- (iii) Dacă $A \in \mathcal{M}_n(\mathbb{R})$ este **simetrică**, atunci

$$\|P^{-1}A\|_P = \rho(P^{-1}A)$$

Dem.

- (i) $P^{-1}A$ este simetrică în raport cu $(\cdot, \cdot)_P \iff$

$$\begin{aligned} (P^{-1}Av, u)_P &= (v, P^{-1}Au)_P, \quad (\forall) u, v \in \mathbb{R}^n \\ \Rightarrow v^T A^T (P^{-1})^T P u &= v^T P^T P^{-1} A u \quad (A = A^T, P = P^T) \\ \Rightarrow v^T A P^{-1} P u &= v^T P P^{-1} A u \Rightarrow v^T A u = v^T A u \quad (A) \end{aligned}$$

- (ii) $P^{-1}A$ este PD în raport cu $(\cdot, \cdot)_P \iff$

$$(P^{-1}Av, v)_P > 0, \quad (\forall) v \in \mathbb{R}^n, v \neq 0 \Rightarrow v^T A^T (P^{-1})^T P v > 0 \Rightarrow v^T A^T v > 0 \quad (P = P^T) \Rightarrow \langle Av, v \rangle_2 > 0 \quad (A)$$

- (iii) Pentru demonstrarea acestui punct, se vor folosi rezultatele de la lemele 1 și 2.

Lema 1 Fie P o matrice SPD. Atunci $\|A\|_P = \|P^{1/2}AP^{-1/2}\|_2$.

Dem.

$$\|A\|_P = \max_v \frac{\|Av\|_P}{\|v\|_P} = \max_v \frac{\sqrt{(Av)^T P (Av)}}{\sqrt{v^T P v}} \quad (*)$$

$$\text{Considerăm } y = P^{1/2}v, \quad v = P^{-1/2}y$$

$$(*) = \max_y \frac{\sqrt{(AP^{-1/2}y)^T P (AP^{-1/2}y)}}{\sqrt{(P^{-1/2}y)^T P P^{-1/2}y}}$$

1. $(AP^{-1/2}y)^T P AP^{-1/2}y = y^T P^{-1/2} A^T P AP^{-1/2}y = y^T P^{-1/2} A^T P^{1/2} P^{1/2} AP^{-1/2}y$
 $= (P^{1/2}AP^{-1/2}y)^T (P^{1/2}AP^{-1/2}y) = \|P^{1/2}AP^{-1/2}y\|_2^2$
2. $(P^{-1/2}y)^T P P^{-1/2}y = y^T P^{-1/2} P P^{-1/2}y = y^T y = \|y\|_2^2$

$$\text{Rezultă: } \|A\|_P = \max_y \frac{\|P^{1/2}AP^{-1/2}y\|_2}{\|y\|_2} = \|P^{1/2}AP^{-1/2}\|_2.$$

□

Lema 2 Fie A și $B \in \mathbb{R}^{n \times n}$. Dacă există $P \in \mathbb{R}^{n \times n}$ nesară a.î. $B = P^{-1}AP$, atunci A și B au același set de valori proprii (și se numesc similare).

Dem.

$$\begin{aligned}
 P_B(\lambda) &= \det(B - \lambda I_n) = \det(P^{-1}AP - \lambda I_n) = \\
 &= \det(P^{-1}AP - \lambda P^{-1}P) = \\
 &= \det(P^{-1}(A - \lambda I_n)P) = \\
 &= \det(P^{-1}) \cdot \det(A - \lambda I_n) \cdot \det(P) = \\
 &= \frac{1}{\det(P)} \cdot \det(A - \lambda I_n) \cdot \det(P) = \\
 &= \det(A - \lambda I_n) = P_A(\lambda).
 \end{aligned}$$

□

Revenind la demonstrația (iii):

$$\|P^{-1}A\|_P = \|P^{1/2}(P^{-1}A)P^{-1/2}\|_2 = \|P^{-1/2}AP^{-1/2}\|_2 \quad (\text{cf. Lema 1})$$

Matricea $P^{-1/2}AP^{-1/2}$ este simetrică $\Rightarrow$ norma sa euclidiană este egală cu raza spectrală:

$$\|P^{-1/2}AP^{-1/2}\|_2 = \rho(P^{-1/2}AP^{-1/2})$$

Conform **Lemei 2**, matricile $P^{-1/2}AP^{-1/2}$ și $P^{-1}A$ sunt similare deoarece:

$$P^{-1/2}AP^{-1/2} = P^{1/2}(P^{-1}A)P^{-1/2}$$

Deci au aceleași valori proprii, ceea ce implică:

$$\rho(P^{-1/2}AP^{-1/2}) = \rho(P^{-1}A)$$

□

Teorema II. Convergența PR-SD.

Fie $A \in \mathcal{M}_n(\mathbb{R})$ **SPD**. Considerăm șirul $\{x^{(k)}\} \subset \mathbb{R}^n$, $k \geq 0$, dat de algoritmul PR-SD (preconditioned steepest descent) și $\{\omega_k\}$ dată conform (7).

$$\Rightarrow \lim_{k \rightarrow \infty} x^{(k)} = x^* \quad (\text{metoda PR-SD converge})$$

Dem.

$$\begin{aligned}
 \|e^{(k)}\|_A^2 &= \|e^{(k-1)} - \omega_{k-1}z^{(k-1)}\|_A^2 = \\
 &= \|e^{(k-1)}\|_A^2 - 2\omega_{k-1}(e^{(k-1)}, z^{(k-1)})_A + \omega_{k-1}^2\|z^{(k-1)}\|_A^2 = \\
 &= \|e^{(k-1)}\|_A^2 - 2\frac{(e^{(k-1)}, z^{(k-1)})_A}{\|z^{(k-1)}\|_A^2}(e^{(k-1)}, z^{(k-1)})_A + \frac{(e^{(k-1)}, z^{(k-1)})_A^2}{\|z^{(k-1)}\|_A^4}\|z^{(k-1)}\|_A^2 = \\
 &= \|e^{(k-1)}\|_A^2 - \frac{(e^{(k-1)}, z^{(k-1)})_A^2}{\|z^{(k-1)}\|_A^2}
 \end{aligned} \tag{1}$$

$$A \rightarrow \text{SPD} \Rightarrow \|z^{(k-1)}\|_A^2 = 0 \iff z^{(k-1)} = 0 \quad (2)$$

$$\begin{aligned} (e^{(k-1)}, z^{(k-1)})_A &= (A^{-1}r^{(k-1)}, z^{(k-1)})_A = \langle r^{(k-1)}, z^{(k-1)} \rangle_2 = \\ &= \langle Pz^{(k-1)}, z^{(k-1)} \rangle_2 = \|z^{(k-1)}\|_P^2 \end{aligned} \quad (3)$$

Conform (1), (2), (3) eroarea are o descreștere **strict** monotonă cât timp $x^{(k)} \neq x^* \Rightarrow$
PR-SD converge. $\square$

Cursul IV

I. Lemă (Inegalitatea Kantorovich).

Fie $A \in \mathcal{M}_n(\mathbb{R})$ o matrice **SPD** și $0 < \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$ valorile proprii ale lui A .

Se notează numărul de condiționare al lui A cu $K := \text{cond}_2(A) = \|A\|_2 \|A^{-1}\|_2 = \frac{\lambda_n}{\lambda_1}$. Atunci:

$$\frac{\|x\|_A \|x\|_{A^{-1}}}{\|x\|_2^2} \leq \frac{1}{2} \left(\sqrt{K} + \frac{1}{\sqrt{K}} \right), \quad \forall x \in \mathbb{R}^n, x \neq 0$$

Dem.

Conform Teoremei Spectrale,

$$\|x\|_A = \sqrt{x^T A x} = \sqrt{x^T Q \Lambda Q^T x} \quad (*)$$

Considerăm $y = Q^T x$.

$$(*) \Rightarrow y^T \Lambda y = \|y\|_\Lambda = \sqrt{\sum_{i=1}^n \lambda_i y_i^2}$$

Analog, pentru $\|x\|_{A^{-1}}$, $\|y\|_{\Lambda^{-1}} = \sqrt{\sum_{i=1}^n \frac{1}{\lambda_i} y_i^2}$.

Obs. $(\lambda_n - \lambda_i)(\lambda_i - \lambda_1) \geq 0, (\forall) i \iff$

$$\iff \lambda_n \lambda_i - \lambda_n \lambda_1 - \lambda_i^2 + \lambda_i \lambda_1 \geq 0$$

$$\iff \lambda_n \lambda_1 + \lambda_i^2 \leq \lambda_n \lambda_i + \lambda_i \lambda_1$$

$$\iff \lambda_n \lambda_1 \cdot \frac{1}{\lambda_i} + \lambda_i \leq \lambda_1 + \lambda_n$$

Se înmulțește cu y_i^2 pentru $i = \overline{1, n}$:

$$\iff \sum_{i=1}^n \lambda_n \lambda_1 \cdot \frac{1}{\lambda_i} \cdot y_i^2 + \sum_{i=1}^n \lambda_i \cdot y_i^2 \leq \sum_{i=1}^n (\lambda_1 + \lambda_n) y_i^2$$

$$\iff \lambda_n \lambda_1 \sum_{i=1}^n \frac{1}{\lambda_i} y_i^2 + \sum_{i=1}^n \lambda_i y_i^2 \leq (\lambda_1 + \lambda_n) \sum_{i=1}^n y_i^2$$

$$\iff \lambda_n \lambda_1 \|y\|_{\Lambda^{-1}}^2 + \|y\|_\Lambda^2 \leq (\lambda_1 + \lambda_n) \|y\|_2^2$$

Fie $a = \lambda_n \lambda_1 \|y\|_{\Lambda^{-1}}^2$, $b = \|y\|_\Lambda^2$. Conform inegalității $4ab \leq (a+b)^2$:

$$\begin{aligned} 4\lambda_n \lambda_1 \|y\|_{\Lambda^{-1}}^2 \cdot \|y\|_\Lambda^2 &\leq (\lambda_n \lambda_1 \|y\|_{\Lambda^{-1}}^2 + \|y\|_\Lambda^2)^2 \leq [(\lambda_1 + \lambda_n) \|y\|_2^2]^2 \\ &\Rightarrow 4\lambda_n \lambda_1 \|y\|_\Lambda^2 \|y\|_{\Lambda^{-1}}^2 \leq [(\lambda_1 + \lambda_n) \|y\|_2^2]^2 \\ &\Rightarrow 2\sqrt{\lambda_n \lambda_1} \|y\|_\Lambda \|y\|_{\Lambda^{-1}} \leq (\lambda_1 + \lambda_n) \|y\|_2^2 \\ &\Rightarrow \frac{\|y\|_\Lambda \cdot \|y\|_{\Lambda^{-1}}}{\|y\|_2^2} \leq \frac{\lambda_1 + \lambda_n}{2\sqrt{\lambda_1 \lambda_n}} \quad (1) \end{aligned}$$

Obs.

$$\begin{aligned}
 \frac{1}{2} \left(\sqrt{K} + \frac{1}{\sqrt{K}} \right) &= \frac{K+1}{2\sqrt{K}} = \frac{\frac{\lambda_n}{\lambda_1} + 1}{2\sqrt{\frac{\lambda_n}{\lambda_1}}} \\
 &= \frac{\frac{\lambda_1 + \lambda_n}{\lambda_1}}{2\sqrt{\lambda_n} \cdot \frac{1}{\sqrt{\lambda_1}}} = \frac{\frac{\lambda_1 + \lambda_n}{\lambda_1}}{2\frac{\sqrt{\lambda_n}}{\sqrt{\lambda_1}}} \\
 &= \frac{\lambda_1 + \lambda_n}{2\sqrt{\lambda_n} \cdot \sqrt{\lambda_1}} = \frac{\lambda_1 + \lambda_n}{2\sqrt{\lambda_1 \lambda_n}} \quad (2)
 \end{aligned}$$

Conform (1), (2):

$$\begin{aligned}
 \frac{\|y\|_{\Lambda} \cdot \|y\|_{\Lambda^{-1}}}{\|y\|_2^2} &\leq \frac{1}{2} \left(\sqrt{K} + \frac{1}{\sqrt{K}} \right) \\
 \Rightarrow \frac{\|Q^T x\|_{\Lambda} \cdot \|Q^T x\|_{\Lambda^{-1}}}{\|Q^T x\|_2^2} &\leq \frac{1}{2} \left(\sqrt{K} + \frac{1}{\sqrt{K}} \right) \\
 \Rightarrow \frac{\|x\|_A \cdot \|x\|_{A^{-1}}}{\|x\|_2^2} &\leq \frac{1}{2} \left(\sqrt{K} + \frac{1}{\sqrt{K}} \right),
 \end{aligned}$$

deoarece norma euclidiană a unui vector este invariantă la transformări ortogonale.

□

Cursul V

Teorema 1 (proprietăți ale CGM).

Fie algoritmul CGM (Conjugate Gradient Method). Atunci au loc următoarele proprietăți:

- (i) $r^{(k)} = r^{(k-1)} - \alpha_k A p^{(k)}, \quad \forall k \geq 1$
- (ii) $P_k^T r^{(k)} := \text{col}[p^{(1)}, p^{(2)}, \dots, p^{(k)}]^T r^{(k)} = 0_k, \quad \forall k \geq 1$
- (iii) $\text{span}\{p^{(1)}, p^{(2)}, \dots, p^{(k)}\} = \text{span}\{r^{(0)}, r^{(1)}, \dots, r^{(k-1)}\} = \mathcal{K}_k(r^{(0)}, A), \quad \forall k \geq 1$
- (iv) $(r^{(i)})^T r^{(j)} = 0, \quad \forall 0 \leq i < j \leq k, \forall k \geq 1$

Dem.

i)

$$\begin{aligned}
 r^{(k)} &= b - Ax^{(k)} \\
 &= b - A(x^{(k-1)} + \alpha_k p^{(k)}) \\
 &= (b - Ax^{(k-1)}) - \alpha_k A p^{(k)} \\
 &= r^{(k-1)} - \alpha_k A p^{(k)}
 \end{aligned}$$

ii)

Fie $P(k)$ propoziția care afirmă că $P_k^T r^{(k)} = 0_k$.

Pentru $P(0)$:

$$\begin{aligned}
 r^{(1)} &= r^{(0)} - \alpha_1 A p^{(1)} \\
 (p^{(1)})^T r^{(1)} &= (p^{(1)})^T r^{(0)} - \alpha_1 (p^{(1)})^T A p^{(1)} \\
 &= \langle (p^{(1)}), r^{(0)} \rangle_2 - \frac{\langle p^{(1)}, r^{(0)} \rangle_2}{\langle p^{(1)}, p^{(1)} \rangle_A} \langle p^{(1)}, p^{(1)} \rangle_A \\
 &= 0
 \end{aligned}$$

Se consideră $P(k)$ adevărată și se demonstrează că $P(k) \implies P(k+1)$:

$$\begin{aligned}
 r^{(k+1)} &= r^{(k)} - \alpha_{k+1} A p^{(k+1)} \\
 P_{k+1}^T r^{(k+1)} &= P_{k+1}^T r^{(k)} - \alpha_{k+1} P_{k+1}^T A p^{(k+1)} \\
 &= \begin{bmatrix} P_k^T r^{(k)} \\ (p^{(k+1)})^T r^{(k)} \end{bmatrix} - \alpha_{k+1} \begin{bmatrix} P_k^T A p^{(k+1)} \\ (p^{(k+1)})^T A p^{(k+1)} \end{bmatrix}
 \end{aligned}$$

Din ipoteza de inducție și proprietatea de A -ortogonalitate a direcțiilor, rezultă că:

$$P_{k+1}^T r^{(k+1)} = \begin{bmatrix} 0 \\ \vdots \\ 0 \\ (p^{(k+1)})^T r^{(k)} \end{bmatrix} - \alpha_{k+1} \begin{bmatrix} 0 \\ \vdots \\ 0 \\ (p^{(k+1)})^T A p^{(k+1)} \end{bmatrix}$$

Pentru a ajunge la vectorul nul:

$$\begin{aligned} & \langle p^{(k+1)}, r^{(k)} \rangle_2 - \alpha_{k+1} \langle p^{(k+1)}, p^{(k+1)} \rangle_A \\ &= \langle p^{(k+1)}, r^{(k)} \rangle_2 - \frac{\langle p^{(k+1)}, r^{(k)} \rangle_2}{\langle p^{(k+1)}, p^{(k+1)} \rangle_A} \langle p^{(k+1)}, p^{(k+1)} \rangle_A = 0 \end{aligned}$$

iii)

Fie $R^{(k)} := \text{span}\{r^{(0)}, r^{(1)}, \dots, r^{(k-1)}\}$ si $P^{(k)} := \text{span}\{p^{(1)}, p^{(2)}, \dots, p^{(k)}\}$.

Fie $P(k)$ propoziția care afirmă că $P^{(k)} = R^{(k)} = \mathcal{K}_k(r^{(0)}, A)$, $\forall k \geq 1$.

Pentru $P(1)$:

$$P^{(1)} = p^{(1)} = r^{(0)} = R^{(1)} = \mathcal{K}_1(r^{(0)}, A)$$

Se consideră $P(k)$ adevărată și se demonstrează că $P(k) \implies P(k+1)$:

$$1. R^{(k+1)} = \mathcal{K}_{k+1}(r^{(0)}, A)$$

Din relatia de recurenta $r^{(k)} = r^{(k-1)} - \alpha_k A p^{(k)}$, $r^{(k-1)} \in \mathcal{K}_k(r^{(0)}, A)$, conform ipotezei de inductie. Cum si $p^{(k)} \in \mathcal{K}_k(r^{(0)}, A)$, tot conform ipotezei de inductie, inseamna ca:

$$\begin{aligned} p^{(k)} &= c_0 r^{(0)} + c_1 (A r^{(0)}) + c_2 (A^2 r^{(0)}) + \dots + c_{k-1} (A^{k-1} r^{(0)}) \implies \\ A p^{(k)} &= c_0 (A r^{(0)}) + c_1 (A^2 r^{(0)}) + c_2 (A^3 r^{(0)}) + \dots + c_{k-1} (A^k r^{(0)}) \implies \\ A p^{(k)} &\in \mathcal{K}_{k+1}(r^{(0)}, A). \end{aligned}$$

In consecinta, $r^{(k)} \in \mathcal{K}_{k+1}(r^{(0)}, A)$.

Considerand ca algoritmul nu converge la iteratia $k+1$, intrucat $P_k^T r^{(k)} = 0_k$, inseamna ca $\dim(R^{(k+1)}) = \dim(P^{(k)}) + 1 = \dim(\mathcal{K}_k(r^{(0)}, A)) + 1 = \dim(\mathcal{K}_{k+1}(r^{(0)}, A))$, conform ipotezei de inductie.

Conform incluziunii si dimensiunilor egale, $R^{(k+1)} = \mathcal{K}_{k+1}(r^{(0)}, A)$.

$$2. P^{(k+1)} = \mathcal{K}_{k+1}(r^{(0)}, A)$$

Din relatia $p^{(k+1)} = r^{(k)} - A P_k z^{(k)}$, $r^{(k)} \in \mathcal{K}_{k+1}(r^{(0)}, A)$, conform demonstratiei anterioare, iar din faptul ca $A P_k z^{(k)}$ reprezinta proiectia ortogonala a lui $r^{(k)}$ pe $\text{span}\{A p^{(1)}, \dots, A p^{(k)}\}$, inseamna ca $A P_k z^{(k)} \in A P^{(k)}$. Dar, conform ipotezei de inductie, $A P^{(k)} = A \mathcal{K}_k(r^{(0)}, A) \subset \mathcal{K}_{k+1}(r^{(0)}, A)$. In consecinta, $p^{(k+1)} \in \mathcal{K}_{k+1}(r^{(0)}, A)$.

Considerand ca algoritmul nu converge la iteratia $k+1$, conform independentei liniare a directiilor $p^{(k)} \implies \dim(P^{(k+1)}) = \dim(P^{(k)}) + 1 = \dim(\mathcal{K}_k(r^{(0)}, A)) + 1 = \dim(\mathcal{K}_{k+1}(r^{(0)}, A))$.

Conform incluziunii si dimensiunilor egale, $P^{(k+1)} = \mathcal{K}_{k+1}(r^{(0)}, A)$.

iv)

Intrucat s-a demonstrat la **ii)** ca $r^{(k)} \perp P^{(k)}$, iar la **iii)** ca $P^{(k)} = R^{(k)}$, rezulta ortogonalitatea tuturor reziduurilor intre ele.

□

Cursul VI

Propozitia 2 (CGM - metoda directa)

Fie $A \in \mathcal{M}_n(\mathbb{R})$ SPD si $u^{(i)} \in \mathbb{R}^n, i = \overline{1, n}$, vectorii proprii ai lui A . Daca $b = \sum_{l=1}^k \gamma_l u^{(i_l)} \in \mathbb{R}^n$, atunci algoritmul CGM pentru $Ax = b$, cu punctul de start $x^{(0)} = 0 \in \mathbb{R}^n$, produce solutia exacta $x^* := A^{-1}b$ in cel mult k iteratii.

Dem. Conform Teoremei Spectrale, $Au^{(i)} = \lambda_i u^{(i)} \implies A^{-1}u^{(i)} = \frac{1}{\lambda_i} u^{(i)}$. Atunci:

$$\begin{aligned} x^* &= A^{-1}b \\ &= A^{-1} \sum_{l=1}^k \gamma_l u^{(i_l)} \\ &= \sum_{l=1}^k \frac{\gamma_l}{\lambda_{i_l}} u^{(i_l)}, \end{aligned}$$

iar

$$x^{(0)} - x^* = - \sum_{l=1}^k \frac{\gamma_l}{\lambda_{i_l}} u^{(i_l)}.$$

Se considera polinomul $p(\lambda)$ cu radacinile λ_{i_l} , pentru care $p(0) = 1$, definit prin:

$$p(\lambda) = \prod_{j=1}^k \left(1 - \frac{\lambda}{\lambda_{i_j}}\right).$$

Atunci:

$$\begin{aligned} p(A)(x^{(0)} - x^*) &= p(A) \left(- \sum_{l=1}^k \frac{\gamma_l}{\lambda_{i_l}} u^{(i_l)} \right) \\ &= - \sum_{l=1}^k \frac{\gamma_l}{\lambda_{i_l}} p(A) u^{(i_l)} \\ &= - \sum_{l=1}^k \frac{\gamma_l}{\lambda_{i_l}} p(\lambda_{i_l}) u^{(i_l)} \\ &= 0, \end{aligned}$$

conform constructiei polinomului $p(\lambda)$.

Intrucat exista un polinom $p \in P_k$ cu $p(0) = 1$ astfel incat $p(A)(x^{(0)} - x^*) = 0$, iar minimizeaza $\|x^{(k)} - x^*\|_A = \min_{p \in P_k: p(0)=1} \|p(A)(x^{(0)} - x^*)\|_A = 0 \implies x^{(k)} = x^*$, ceea ce inseamna CGM produce solutia exacta in cel mult k iteratii.

□

Propozitia 1 (CGM - metoda directa)

Fie $A \in \mathcal{M}_n(\mathbb{R})$ o matrice simetrica si pozitiv definita (SPD) si $b \in \mathbb{R}^n$. Atunci algoritmul CGM produce solutia sistemului $Ax = b$ in maximum n iteratii, cu aritmetica exacta (i.e., fara erori de rotunjire).

Dem. Conform Propozitiei 2, pentru b o combinatie liniara dintre cei n vectorii proprii ai lui A , $x^{(n)} = x^*$, iar CGM produce solutia exacta in cel mult n pasi.

Alternativ, se poate demonstra convergenta in n iteratii alegand polinomul caracteristic al matricii A care, conform Teoremei Cayley-Hamilton, isi satisface propriul polinom caracteristic. $\square$

Propozitia 3 (CGM - metoda directa)

Fie $A \in \mathcal{M}_n(\mathbb{R})$ SPD care are $k \leq n$ valori proprii distincte si $b \in \mathbb{R}^n$. Atunci CGM produce solutia sistemului $Ax = b$ in cel mult k iteratii, in aritmetica exacta.

Dem. Conform Propozitiei 2, reiese din alegerea polinomului $p(A)$ ca pentru b o combinatie liniara dintre cei k vectorii proprii distincti ai lui A , $x^{(k)} = x^*$, iar CGM produce solutia exacta in cel mult k pasi. $\square$

Propozitia 4 (CGM - metoda directa)

Fie $A = I_n + B \in \mathcal{M}_n(\mathbb{R})$ SPD, unde $\text{rang}(B) = k$ si $b \in \mathbb{R}^n$. Atunci CGM produce solutia sistemului $Ax = b$ in cel mult $k + 1$ iteratii, in aritmetica exacta.

Dem. Intrucat $\text{rang}(B) = k = \dim(B)$, inseamna ca B poate avea cel mult k valori proprii nenule, ceea ce inseamna ca poate avea cel mult $k + 1$ valori proprii distincte.

Consideram $\lambda \in \sigma(A)$ si $\mu \in \sigma(B)$ si v_i , $i \in \{1, \dots, n\}$ vectorii proprii asociati matricii A . Atunci:

$$\begin{aligned} Av &= (I_n + B)v \\ &= I_nv + Bv \\ &= v + \mu v \\ &= (1 + \mu)v, \end{aligned}$$

ceea ce inseamna ca:

$$\lambda_i = 1 + \mu_i, \forall i \in \{1, \dots, n\}.$$

Pentru $\mu_i = 0$, $\lambda_i = 1 \implies$ matricea A are cel mult $k + 1$ valori proprii distincte. Conform Propozitiei 3, CGM produce solutia exacta in cel mult $k + 1$ pasi. $\square$

Obs. I

Se considera sistemul $\tilde{A}\tilde{x} = \tilde{b}$ unde:

$$\tilde{A} := P^{-1/2}AP^{-1/2} \quad (\text{SPD})$$

$$\tilde{x} := P^{1/2}x$$

$$\tilde{b} := P^{-1/2}b \in \mathbb{R}^n$$

Atunci au loc urmatoarele:

- (1) Matricea $\tilde{A}$ este SPD in raport cu $\langle \cdot, \cdot \rangle_2$.
- (2) Prin aplicarea CGM sistemului preconditionat, cu substitutiile corespunzatoare, se obtine acelasi algoritm PCGM.

Dem.

(1)

$\tilde{A}^T = (P^{-1/2}AP^{-1/2})^T = (P^{-1/2})^T A^T (P^{-1/2})^T = P^{-1/2}AP^{-1/2} = \tilde{A}$, deoarece A si P sunt simetrice.

Fie $x \in \mathbb{R}^n, x \neq 0$. Atunci:

$$\begin{aligned} x^T \tilde{A}x &= x^T (P^{-1/2}AP^{-1/2})x \\ &= (P^{-1/2}x)^T A(P^{-1/2}x) \end{aligned}$$

Fie $y = P^{-1/2}x$. Intrucat $P^{-1/2}$ este nesingulara si $x \neq 0 \implies y \neq 0$. Deoarece A este pozitiv definita, $y^T Ay > 0, \forall y \neq 0$.

$$\implies x^T \tilde{A}x > 0$$

In consecinta, $\tilde{A}$ este SPD.

(2)

Fie $\tilde{r} = P^{-1/2}r$ si $\tilde{p} = P^{1/2}p$, reziduul si directia in sistemul preconditionat.

Obs.

$$z = P^{-1}r = P^{-1/2}(P^{-1/2}r) = P^{-1/2}\tilde{r} \implies \tilde{r} = P^{1/2}z.$$

I. α_k

$$\tilde{\alpha}_k = \frac{(\tilde{r}^{(k)})^T \tilde{r}^{(k)}}{(\tilde{p}^{(k)})^T \tilde{A}\tilde{p}^{(k)}}$$

Numaratorul:

$$(\tilde{r}^{(k)})^T \tilde{r}^{(k)} = (P^{-1/2}r^{(k)})^T (P^{-1/2}r^{(k)}) = (r^{(k)})^T P^{-1}r^{(k)} = (r^{(k)})^T z^{(k)}.$$

Numitorul:

$$(\tilde{p}^{(k)})^T \tilde{A}\tilde{p}^{(k)} = (P^{1/2}p^{(k)})^T (P^{-1/2}AP^{-1/2})(P^{1/2}p^{(k)}) = (p^{(k)})^T Ap^{(k)}.$$

Deci $\tilde{\alpha}_k = \frac{(r^{(k)})^T z^{(k)}}{(p^{(k)})^T A p^{(k)}} = \alpha_k.$

II. $x^{(k+1)}$

$$\begin{aligned}\tilde{x}^{(k+1)} &= \tilde{x}^{(k)} + \alpha_k \tilde{p}^{(k)} \\ P^{-1/2} \tilde{x}^{(k+1)} &= P^{-1/2} \tilde{x}^{(k)} + \alpha_k P^{-1/2} \tilde{p}^{(k)}\end{aligned}$$

Deci $\tilde{x}^{(k+1)} = x^{(k)} + \alpha_k p^{(k)} = x^{(k+1)}.$

III. $r^{(k+1)}$

$$\begin{aligned}\tilde{r}^{(k+1)} &= \tilde{r}^{(k)} - \alpha_k \tilde{A} \tilde{p}^{(k)} \\ P^{1/2} \tilde{r}^{(k+1)} &= P^{1/2} \tilde{r}^{(k)} - \alpha_k P^{1/2} (P^{-1/2} A P^{-1/2}) P^{1/2} \tilde{p}^{(k)}\end{aligned}$$

Deci $\tilde{r}^{(k+1)} = r^{(k)} - \alpha_k A p^{(k)} = r^{(k+1)}.$

IV. β_k

$$\tilde{\beta}_k = \frac{(\tilde{r}^{(k+1)})^T \tilde{r}^{(k+1)}}{(\tilde{r}^{(k)})^T \tilde{r}^{(k)}} = \frac{(r^{(k+1)})^T z^{(k+1)}}{(r^{(k)})^T z^{(k)}} = \beta_k$$

V: $p^{(k)}$

$$\begin{aligned}\tilde{p}^{(k+1)} &= \tilde{r}^{(k+1)} + \beta_k \tilde{p}^{(k)} \\ P^{-1/2} \tilde{p}^{(k+1)} &= P^{-1/2} \tilde{r}^{(k+1)} + \beta_k P^{-1/2} \tilde{p}^{(k)}\end{aligned}$$

Deci $\tilde{p}^{(k+1)} = z^{(k+1)} + \beta_k p^{(k)} = p^{(k+1)}.$

□

Obs. II

Se considera sistemul $\hat{A}\hat{x} = \hat{b}$ unde:

$$\begin{aligned}\hat{A} &:= H^{-1} A H^{-T} \quad (\text{SPD}) \\ \hat{x} &:= H^T x \\ \hat{b} &:= H^{-1} b \in \mathbb{R}^n\end{aligned}$$

Atunci au loc urmatoarele:

- (1) Matricea $\hat{A}$ este SPD in raport cu $\langle \cdot, \cdot \rangle_2$.
- (2) Prin aplicarea CGM sistemului preconditionat, cu substitutiile corespunzatoare, se obtine acelasi algoritm PCGM.

Dem.

(1)

$\hat{A}^T = (H^{-1}AH^{-T})^T = (H^{-T})^T A^T H^{-T} = H^{-1}AH^{-T} = \hat{A}$, deoarece A este simetrica.

Fie $x \in \mathbb{R}^n, x \neq 0$. Atunci:

$$\begin{aligned} x^T \hat{A}x &= x^T (H^{-1}AH^{-T})x \\ &= (H^{-T}x)^T A(H^{-T}x). \end{aligned}$$

Fie $y = H^{-T}x$. Intrucat P este SPD, inseamna ca $\det(P) > 0$, iar $\det(P) = \det(HH^T) = \det(H)^2$. Intrucat patratul lui $\det(H)$ e un numar strict pozitiv, $\det(H)$ nu poate fi 0, de unde rezulta nesingularitatea lui H . A este SPD, deci $y^T Ay > 0, \forall x \neq 0$.

In consecinta, $\hat{A}$ este SPD.

(2)

Fie:

$$\begin{aligned} \hat{r}^{(k)} &= H^{-1}r^{(k)} & (\hat{b} - \hat{A}\hat{x}^{(k)} &= H^{-1}(b - Ax^{(k)})) \\ z^{(k)} &= H^{-T}\hat{r}^{(k)} & (z = P^{-1}r = (HH^T)^{-1}r = H^{-T}(H^{-1}r)) \\ \hat{p}^{(k)} &= H^T p^{(k)}. \end{aligned}$$

I. α_k

$$\hat{\alpha}_k = \frac{(\hat{r}^{(k)})^T \hat{r}^{(k)}}{(\hat{p}^{(k)})^T \hat{A}\hat{p}^{(k)}}$$

Numaratorul:

$$(\hat{r}^{(k)})^T \hat{r}^{(k)} = (H^{-1}r^{(k)})^T (H^{-1}r^{(k)}) = (r^{(k)})^T H^{-T}H^{-1}r^{(k)} = (r^{(k)})^T z^{(k)}.$$

Numitorul:

$$(\hat{p}^{(k)})^T \hat{A}\hat{p}^{(k)} = (H^T p^{(k)})^T (H^{-1}AH^{-T})(H^T p^{(k)}) = (p^{(k)})^T Ap^{(k)}.$$

$$\text{Deci } \hat{\alpha}_k = \frac{(r^{(k)})^T z^{(k)}}{(p^{(k)})^T Ap^{(k)}} = \alpha_k.$$

II. $x^{(k+1)}$

$$\begin{aligned} \hat{x}^{(k+1)} &= \hat{x}^{(k)} + \alpha_k \hat{p}^{(k)} \\ H^{-T}\hat{x}^{(k+1)} &= H^{-T}\hat{x}^{(k)} + \alpha_k H^{-T}\hat{p}^{(k)} \end{aligned}$$

$$\text{Deci } \hat{x}^{(k+1)} = x^{(k)} + \alpha_k p^{(k)} = x^{(k+1)}.$$

III. $r^{(k+1)}$

$$\hat{r}^{(k+1)} = \hat{r}^{(k)} - \alpha_k \hat{A}\hat{p}^{(k)}$$

$$H\hat{r}^{(k+1)} = H\hat{r}^{(k)} - \alpha_k H(H^{-1}AH^{-T})H^T p^{(k)}$$

$$\text{Deci } \hat{r}^{(k+1)} = r^{(k)} - \alpha_k A p^{(k)} = r^{(k+1)}.$$

IV. β_k

$$\hat{\beta}_k = \frac{(\hat{r}^{(k+1)})^T \hat{r}^{(k+1)}}{(\hat{r}^{(k)})^T \hat{r}^{(k)}} = \frac{(r^{(k+1)})^T z^{(k+1)}}{(r^{(k)})^T z^{(k)}} = \beta_k$$

V. $p^{(k+1)}$

$$\hat{p}^{(k+1)} = \hat{r}^{(k+1)} + \beta_k \hat{p}^{(k)}$$

Înmultim la stanga cu H^{-T} (si folosim relatia $H^{-T}\hat{r} = z$):

$$H^{-T}\hat{p}^{(k+1)} = H^{-T}\hat{r}^{(k+1)} + \beta_k H^{-T}\hat{p}^{(k)}$$

$$\text{Deci } \hat{p}^{(k+1)} = z^{(k+1)} + \beta_k p^{(k)} = p^{(k+1)}.$$

□

Cursul VII

Corolar Lema Banach

$$\forall F \in \mathcal{M}_n(\mathbb{R}) : \|F\| < 1,$$

$$\|(I_n - F)^{-1} - I_n\| \leq \frac{\|F\|}{1 - \|F\|}$$

Dem.

$$\begin{aligned} (I_n - F)^{-1} &= \sum_{k=0}^{\infty} F^k \\ (I_n - F)^{-1} - I_n &= \sum_{k=1}^{\infty} F^k \\ &= F \sum_{k=0}^{\infty} F^k \\ &= F(I_n - F)^{-1}. \end{aligned}$$

Atunci:

$$\begin{aligned} \|(I_n - F)^{-1} - I_n\| &= \|F(I_n - F)^{-1}\| \\ &\leq \|F\| \|(I_n - F)^{-1}\| \\ &\leq \|F\| \frac{1}{1 - \|F\|} \\ &= \frac{\|F\|}{1 - \|F\|}. \end{aligned}$$

□

Teorema 1. Daca $A \in \mathcal{M}_n(\mathbb{R})$ este inversabila si $E \in \mathcal{M}_n(\mathbb{R})$ a.i. $r := \|A^{-1}E\| < 1$, atunci

(i) $A + E \in \mathcal{M}_n(\mathbb{R})$ este inversabila

(ii) $\|(A + E)^{-1} - A^{-1}\| \leq \frac{\|E\| \cdot \|A^{-1}\|^2}{1 - r}$

Dem.

i) P.p. ca $A + E \rightarrow$ singulara. Deci $(\exists)x \in \mathbb{R}^n \neq 0$ a.i. $(A + E)x = 0$.

$$\begin{aligned} Ax + Ex &= 0 \\ Ax &= -Ex \\ x &= -A^{-1}Ex \\ \|x\| &= \| -A^{-1}Ex \| \\ \|x\| &\leq \|A^{-1}E\| \|x\| \\ 1 &\leq \|A^{-1}E\|, \end{aligned}$$

ceea ce e o contradicție $\implies A$ este nesusingulară și inversabilă.

ii)

$$A + E = A(I_n + A^{-1}E) = A[I_n - (-A^{-1}E)]$$

Considerând $F \in \mathcal{M}_n(\mathbb{R})$, $F = -A^{-1}E$, rezulta că:

$$\begin{aligned} \|(A + E)^{-1} - A^{-1}\| &= \|[A(I_n - F)]^{-1} - A^{-1}\| \\ &= \|(I_n - F)^{-1} \cdot A^{-1} - A^{-1}\| \\ &= \|A^{-1}[(I_n - F)^{-1} - I_n]\| \\ &\leq \|A^{-1}\| \|(I_n - F)^{-1} - I_n\|, \end{aligned}$$

care, conform corolarului Lemei Banach,

$$\leq \|A^{-1}\| \cdot \frac{\|F\|}{1 - \|F\|}.$$

Înlocuind F cu $-A^{-1}E$ și ținând cont de invarianța normei matriceale la schimbarea de semn,

$$\begin{aligned} \|(A + E)^{-1} - A^{-1}\| &\leq \|A^{-1}\| \cdot \frac{\|A^{-1}E\|}{1 - \|A^{-1}E\|} \\ &\leq \frac{\|E\| \|A^{-1}\|^2}{1 - r}. \end{aligned}$$

□

Exercițiul I Să se determine $h^{(k)}$ dat de metoda Newton-Jacobi cu $m \in \mathbb{N}$ pași, i.e., Jacobi(m).

Dem.

Conform cursului, pentru metoda Newton-Richardson Stationară:

$$h^{(k)} := - \sum_{j=0}^{m-1} (M^{(k)})^j \cdot (P^{(k)})^{-1} \cdot F(x^{(k)})$$

În particular, pentru metoda Newton-Jacobi:

$$\begin{aligned} h^{(k)} &:= - \sum_{j=0}^{m-1} (M_J^{(k)})^j \cdot (P_J^{(k)})^{-1} \cdot F(x^{(k)}) \\ &= \sum_{j=0}^{m-1} [(D^{(k)})^{-1}(L^{(k)} + U^{(k)})]^j \cdot (D^{(k)})^{-1} \cdot F(x^{(k)}), \end{aligned}$$

unde D , U și L sunt părțile aditive ale matricii $J_F(x^{(k)})$.

□

Cursul VIII

Exercitiul 1 Sa se reia analiza aproximarii cu diferente finite centrale a lui $J_F(x^{(k)})$ cu $J_{\tilde{h}}^{(k)}$ referitoare la:

- corectitudinea aproximarii $J_{\tilde{h}}^{(k)}$,
- normalizarea lui $J_{\tilde{h}}^{(k)}$,
- analiza erorii de aproximare.

Dem.

- corectitudinea

$$\begin{aligned}
 J_F(x^{(k)})w &= J_F(x^{(k)}) \left(\sum_{j=1}^n w_j e^{(j)} \right) \\
 &= \sum_{j=1}^n w_j [J_F(x^{(k)})e^{(j)}] \\
 &= \sum_{j=1}^n w_j \frac{\partial F}{\partial x_j}(x^{(k)}) \\
 &\simeq \sum_{j=1}^n w_j \frac{1}{2\tilde{h}_j^{(k)}} \left[F(x^{(k)} + \tilde{h}_j^{(k)} e^{(j)}) - F(x^{(k)} - \tilde{h}_j^{(k)} e^{(j)}) \right] \\
 &= \sum_{j=1}^n w_j \left[\tilde{J}_{\tilde{h}}^{(k)} e^{(j)} \right] \\
 &= \tilde{J}_{\tilde{h}}^{(k)} \left(\sum_{j=1}^n w_j e^{(j)} \right) \\
 &= J_{\tilde{h}}^{(k)} w
 \end{aligned}$$

In consecinta, $J_F(x^{(k)})w \simeq J_{\tilde{h}}^{(k)}w$, $\forall w \in \mathbb{R}^n$.

- normalizarea

$$\frac{\partial F}{\partial x_j}(x^{(k)}) \simeq \begin{cases} \frac{1}{2\tilde{h}_j^{(k)} \|x^{(k)}\|} \left[F(x^{(k)} + \tilde{h}_j^{(k)} e^{(j)}) - F(x^{(k)} - \tilde{h}_j^{(k)} e^{(j)}) \right], & \text{dacă } x^{(k)} \neq 0 \\ \frac{1}{2\tilde{h}_j^{(k)}} \left[F(x^{(k)} + \tilde{h}_j^{(k)} e^{(j)}) - F(x^{(k)} - \tilde{h}_j^{(k)} e^{(j)}) \right], & \text{dacă } x^{(k)} = 0 \end{cases}$$

- analiza erorii

$$\begin{aligned}
 (\tilde{J}_{\tilde{h}}^{(k)})_{\cdot,j} &= \frac{\tilde{F}(x^{(k)} + \tilde{h}_j^{(k)} \|x^{(k)}\| e^{(j)}) - \tilde{F}(x^{(k)} - \tilde{h}_j^{(k)} \|x^{(k)}\| e^{(j)})}{2\tilde{h}_j^{(k)} \|x^{(k)}\|} \\
 &= \frac{F(x^{(k)} + \tilde{h}_j^{(k)} \|x^{(k)}\| e^{(j)}) - F(x^{(k)} - \tilde{h}_j^{(k)} \|x^{(k)}\| e^{(j)})}{2\tilde{h}_j^{(k)} \|x^{(k)}\|} \\
 &\quad + \frac{\mathcal{E}(x^{(k)} + \tilde{h}_j^{(k)} \|x^{(k)}\| e^{(j)}) - \mathcal{E}(x^{(k)} - \tilde{h}_j^{(k)} \|x^{(k)}\| e^{(j)})}{2\tilde{h}_j^{(k)} \|x^{(k)}\|}
 \end{aligned}$$

Eroarea totala a aproximarii este:

$$\begin{aligned}
 \|J_F(x^{(k)})e^{(j)} - (\tilde{J}_{\tilde{h}}^{(k)})_{\cdot,j}\| &\leq \left\| \frac{\partial F}{\partial x_j}(x^{(k)}) - \frac{F(x^{(k)} + \dots) - F(x^{(k)} - \dots)}{2\tilde{h}_j^{(k)} \|x^{(k)}\|} \right\| \\
 &\quad + \left\| \frac{\mathcal{E}(x^{(k)} + \dots) - \mathcal{E}(x^{(k)} - \dots)}{2\tilde{h}_j^{(k)} \|x^{(k)}\|} \right\| \\
 &= O\left((\tilde{h}_j^{(k)})^2 \|x^{(k)}\|^2\right) + O\left(\frac{\epsilon_M}{\tilde{h}_j^{(k)} \|x^{(k)}\|}\right).
 \end{aligned}$$

□

Lema Sherman-Morrison Fie $A \in \mathcal{M}_n(\mathbb{R})$ inversabila si $u, v \in \mathbb{R}^n$. Atunci:

- (i) $A + uv^T \in \mathcal{M}_n(\mathbb{R})$ inversabila $\iff 1 + v^T A^{-1}u \neq 0$,
- (ii) $1 + v^T A^{-1}u \neq 0 \implies$

$$(A + uv^T)^{-1} = A^{-1} - \frac{A^{-1}uv^T A^{-1}}{1 + v^T A^{-1}u}.$$

Dem.

i)

Se considera $w \in \mathbb{R}^n$ a.i. $w = A^{-1}u$. Atunci:

$$A + uv^T = A(I_n + A^{-1}uv^T) = A(I_n + wv^T).$$

Intrucat produsul dintre doua matrici inversabile este o matrice inversabila, demonstratia se reduce la inversabilitatea matricii $B = I_n + wv^T$. Pentru $x \in \mathbb{R}^n$ avem:

$$Bx = (I_n + wv^T)x = x + wv^T x.$$

Cazul $x = w$:

$$Bw = w + wv^T w = w(1 + v^T w),$$

ceea ce inseamna ca w este vectorul propriu al matricii B cu valoarea proprie asociata $\lambda_w = (1 + v^T w)$.

Cazul $x = z : v^T z = 0$:

$$Bz = z + wv^T z = z,$$

ceea ce inseamna ca pe directiile ortogonale lui v , directia e invarianta la transformarea $B \implies \lambda_i = 1, \forall i \in \{1, \dots, n-1\}$.

In consecinta, ca toate valorile proprii ale matricii B sa fie nenule, trebuie ca $\lambda_w = (1 + v^T w) \neq 0$. Prin urmare, inversabilitatea matricii B , si implicit, a matricii A depinde de conditia ca $1 + v^T A^{-1}u \neq 0$.

ii)

Pentru $X, Y \in \mathcal{M}_n(\mathbb{R})$, daca $XY = I_n \implies Y = X^{-1}$. Atunci:

$$\begin{aligned} (A + uv^T) & \left(A^{-1} - \frac{A^{-1}uv^T A^{-1}}{1 + v^T A^{-1}u} \right) \\ &= AA^{-1} - A \frac{A^{-1}uv^T A^{-1}}{1 + v^T A^{-1}u} + uv^T A^{-1} - uv^T \frac{A^{-1}uv^T A^{-1}}{1 + v^T A^{-1}u} \\ &= I_n - \frac{uv^T A^{-1}}{1 + v^T A^{-1}u} + uv^T A^{-1} - \frac{u(v^T A^{-1}u)v^T A^{-1}}{1 + v^T A^{-1}u} \\ &= I_n + uv^T A^{-1} - \frac{uv^T A^{-1} + u(v^T A^{-1}u)v^T A^{-1}}{1 + v^T A^{-1}u} \\ &= I_n + uv^T A^{-1} - \frac{u(1 + v^T A^{-1}u)v^T A^{-1}}{1 + v^T A^{-1}u} \\ &= I_n + uv^T A^{-1} - uv^T A^{-1} \\ &= I_n \end{aligned}$$

□

Cursul IX

Exercitiul 1 Fie norma Frobenius $\|\cdot\|_F : \mathcal{M}_n(\mathbb{R}) \rightarrow [0, \infty)$ definita prin:

$$\|A\|_F^2 := \sum_{i=1}^n \|Av^{(i)}\|_2^2, \quad \forall \{v^{(1)}, \dots, v^{(n)}\} \subset \mathbb{R}^n \text{ sistem ortonormat.}$$

Sa se arate ca:

$$\|A\|_F^2 = \text{tr}(A^T A) = \sum_{i,j=1}^n a_{ij}^2$$

Dem.

Se considera sistemul ortonormat dat de baza canonica $v^{(j)} = e^{(j)}$. Vectorul $Ae^{(j)}$ reprezinta coloana j a matricei A . Atunci:

$$\|A\|_F^2 = \sum_{j=1}^n \|Ae^{(j)}\|_2^2 = \sum_{j=1}^n \left(\sum_{i=1}^n a_{ij}^2 \right) = \sum_{i,j=1}^n a_{ij}^2.$$

Fie $(A^T A)_{jj}$ diagonala principala a matricii $A^T A$. Atunci:

$$\begin{aligned} (A^T A)_{jj} &= \sum_{k=1}^n (A^T)_{jk} A_{kj} = \sum_{k=1}^n a_{kj} a_{kj} = \sum_{k=1}^n a_{kj}^2 \\ \text{tr}(A^T A) &= \sum_{j=1}^n (A^T A)_{jj} = \sum_{j=1}^n \sum_{k=1}^n a_{kj}^2 = \sum_{i,j=1}^n a_{ij}^2. \end{aligned}$$

In consecinta,

$$\|A\|_F^2 = \sum_{i,j=1}^n a_{ij}^2 = \text{tr}(A^T A)$$

□

Exercitiul 2 Sa se demonstreze proprietatile:

1. $\|AB\|_F \leq \min\{\|A\|_2 \|B\|_F, \|A\|_F \|B\|_2\}, \quad \forall A, B \in \mathcal{M}_n(\mathbb{R})$
2. $\|xy^T\|_F = \|xy^T\|_2 = \|x\|_2 \|y\|_2, \quad \forall x, y \in \mathbb{R}^n$
3. $\|AB\| \leq \|A\| \|B\|, \quad \forall A, B \in \mathcal{M}_n(\mathbb{R})$ pentru $\|\cdot\| = \|\cdot\|_2$ și $\|\cdot\| = \|\cdot\|_F$.

Dem.

1.

Fie $b^{(j)}$ coloana j a matricei B . Atunci coloana j a matricei AB este $Ab^{(j)}$.

$$\begin{aligned}\|AB\|_F^2 &= \sum_{j=1}^n \|Ab^{(j)}\|_2^2 \\ &\leq \sum_{j=1}^n (\|A\|_2 \|b^{(j)}\|_2)^2 \\ &= \|A\|_2^2 \sum_{j=1}^n \|b^{(j)}\|_2^2 \\ &= \|A\|_2^2 \|B\|_F^2 \implies \|AB\|_F \leq \|A\|_2 \|B\|_F.\end{aligned}$$

Pentru a doua inegalitate se tine cont de proprietatea de invarianta la operatia de transpunere a normelor matriceale:

$$\|AB\|_F = \|(AB)^T\|_F = \|B^T A^T\|_F \leq \|B^T\|_2 \|A^T\|_F = \|B\|_2 \|A\|_F.$$

In consecinta,

$$\|AB\|_F \leq \min\{\|A\|_2 \|B\|_F, \|A\|_F \|B\|_2\}.$$

2.

$$\begin{aligned}\|xy^T\|_F^2 &= \text{tr}((xy^T)^T(xy^T)) = \text{tr}(yx^Txy^T) \\ &= \text{tr}(y(x^T x)y^T) = (x^T x)\text{tr}(yy^T) \\ &= \|x\|_2^2 \|y\|_2^2 \implies \|xy^T\|_F = \|x\|_2 \|y\|_2\end{aligned}$$

Folosind definitia normei matriceale si inegalitatea Cauchy-Schwarz pentru $|y^T z| \leq \|y\|_2 \|z\|_2$:

$$\begin{aligned}\|xy^T\|_2 &= \sup_{z \neq 0} \frac{\|xy^T z\|_2}{\|z\|_2} = \sup_{z \neq 0} \frac{\|x(y^T z)\|_2}{\|z\|_2} \\ &= \|x\|_2 \sup_{z \neq 0} \frac{|y^T z|}{\|z\|_2} = \|x\|_2 \|y\|_2.\end{aligned}$$

3.

Pentru $\|\cdot\|_2$:

$$\begin{aligned}\|AB\|_2 &= \sup_{\|u\|_2=1} \|ABu\|_2 \leq \sup_{\|u\|_2=1} (\|A\|_2 \|Bu\|_2) \\ &\leq \|A\|_2 \left(\sup_{\|u\|_2=1} \|Bu\|_2 \right) = \|A\|_2 \|B\|_2\end{aligned}$$

Pentru $\|\cdot\|_F$:

Intrucat $\|X\|_2^2 = \lambda_{\max}(X^T X) \leq \text{tr}(X^T X) = \|X\|_F^2 \implies \|X\|_2 \leq \|X\|_F$. Atunci:

$$\|AB\|_F \leq \|A\|_2 \|B\|_2 \leq \|A\|_F \|B\|_F.$$

□

Exercitiul 3 Fie $A = \begin{bmatrix} 4 & 1 \\ -1 & 1 \end{bmatrix}$, $h = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$, $y = \begin{bmatrix} 5 \\ -2 \end{bmatrix}$.

1. Pentru $\|\cdot\| = \|\cdot\|_2$ in Lema 1, sa se arate ca solutia problemei de minimizare

$$B^* = \arg \min_{\{B \in \mathcal{M}_n(\mathbb{R}) | Bh=y\}} \|B - A\|$$

este data de

$$B^* = A + \begin{bmatrix} 1 & \alpha \\ -1 & \alpha \end{bmatrix}, \quad \alpha \in [-1, 1].$$

2. Pentru $\|\cdot\| = \|\cdot\|_F$ si $\|\cdot\|_2$ in Lema 1, sa se determine unica solutie a problemei de minimizare

$$B^* = \arg \min_{\{B \in \mathcal{M}_n(\mathbb{R}) | Bh=y\}} \|B - A\|_F.$$

Dem.

1.

Fie eroarea $z = y - Ah$:

$$z = \begin{bmatrix} 5 \\ -2 \end{bmatrix} - \begin{bmatrix} 4 & 1 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Fie $E = B - A$. Atunci $Bh = y \iff (B - A)h = z$. Intrucat, in cazul general,

$$\|Eh\|_2 \leq \|E\|_2 \|h\|_2 \implies \|E\|_2 \geq \frac{\|Eh\|_2}{\|h\|_2},$$

in cazul acesta:

$$\|E\|_2 \geq \frac{\|z\|_2}{\|h\|_2} = \frac{\sqrt{1^2 + (-1)^2}}{\sqrt{1^2 + 0^2}} = \frac{\sqrt{2}}{1} = \sqrt{2}.$$

Se considera candidatul

$$E = \begin{bmatrix} 1 & \alpha \\ -1 & \alpha \end{bmatrix},$$

pentru care:

$$\|E\|_2 = \sqrt{\lambda_{\max}(E^T E)} = \sqrt{\max\{2, 2\alpha^2\}}.$$

Atingand limita inferioara calculata,

$$\begin{aligned} \|E\|_2 = \sqrt{2} &\iff \sqrt{\max\{2, 2\alpha^2\}} = \sqrt{2} \\ &\iff \max\{2, 2\alpha^2\} = 2 \\ &\iff 2\alpha^2 \leq 2 \iff \alpha^2 \leq 1. \end{aligned}$$

2.

Folosind Proprietatea 1. demonstrata anterior,

$$\begin{aligned} \|AB\|_F &\leq \min\{\|A\|_2 \|B\|_F, \|A\|_F \|B\|_2\} \\ \|AB\|_F &\leq \|A\|_F \|B\|_2. \end{aligned}$$

Fie scalarul $k = \frac{1}{v^T v} = \frac{1}{\|v\|_2^2}$. Conform omogenitatii normei:

$$\left\| \frac{vv^T}{v^T v} \right\|_F = \frac{1}{v^T v} \|vv^T\|_F.$$

Folosind Proprietatea 2. demonstrata anterior,

$$\|vv^T\|_F = \|v\|_2 \|v\|_2 = \|v\|_2^2,$$

Deci:

$$\left\| \frac{vv^T}{v^T v} \right\|_F = \frac{1}{\|v\|_2^2} \cdot \|v\|_2^2 = 1$$

In consecinta, normele sunt conforme cu ipoteza Lemei 1.

Conform Lemei 1, pentru norma Frobenius,

$$B^* = A + \frac{(y - Ah)h^T}{h^T h}.$$

Atunci:

$$Ah = \begin{bmatrix} 4 & 1 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 4 \\ -1 \end{bmatrix},$$

$$y - Ah = \begin{bmatrix} 5 \\ -2 \end{bmatrix} - \begin{bmatrix} 4 \\ -1 \end{bmatrix} = \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

$$h^T h = \|h\|_2^2 = 1^2 + 0^2 = 1,$$

$$\frac{(y - Ah)h^T}{h^T h} = \frac{1}{1} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \begin{bmatrix} 1 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ -1 & 0 \end{bmatrix}.$$

In consecinta,

$$B^* = \begin{bmatrix} 4 & 1 \\ -1 & 1 \end{bmatrix} + \begin{bmatrix} 1 & 0 \\ -1 & 0 \end{bmatrix} = \begin{bmatrix} 5 & 1 \\ -2 & 1 \end{bmatrix}.$$

□